



Universidade do Minho
Escola de Engenharia

David Figueiredo, a104360


Diogo Ferreira, a104266

Filipe Fernandes, a104185

João Macedo, a104080

Relatório

Aprendizagem e Decisões Inteligentes



Índice

1	Introdução	1
1.1	Contextualização	1
1.2	Objetivos e Trabalho proposto	1
1.3	Resumo do trabalho a desenvolver	1
2	Dataset Hospitalar	1
2.1	Estudo do Negócio	1
2.2	Estudo dos Dados	1
2.2.1	Test Results	2
2.2.2	Age	2
2.2.3	Gender	2
2.2.4	Blood Type	3
2.2.5	Medical Condition	3
2.2.6	Insurance Provider	4
2.2.7	Medication	4
2.2.8	Admission Type	4
2.2.9	Correlação entre os atributos	4
2.3	Preparação dos Dados	5
2.3.1	Normalização de valores categóricos	6
2.3.2	Tratamento de valores em falta (missing values)	6
2.3.3	Oversampling dos dados	6
2.3.4	Normalização dos valores numéricos	6
2.4	Modelação	6
2.4.1	Modelação com todos os atributos.	6
2.4.2	Modelação com feature selection.	7
2.4.3	Modelação com os dados em bins.	7
2.5	Avaliação	8
3	Dataset de grupo - car prices	9
3.1	Estudo do Negócio	9
3.2	Estudo dos Dados	9
3.2.1	Análise individual de cada atributo.	10
3.3	Preparação dos Dados	15
3.4	Modelação	15
3.4.1	Modelação com todos os atributos.	15
3.4.2	Modelação com feature selection.	16
3.4.3	Modelação com redes neuronais.	16
3.5	Avaliação	17
4	Conclusão	18

Índice de imagens

Figura 1		2
Figura 2	Distribuição dos géneros dos pacientes (após tratamento de dados).	3
Figura 3		5
Figura 4	Resultados da modelação com todos os atributos.	7
Figura 5	Resultados da modelação com feature selection.	7
Figura 6	Resultados da modelação com dados em bins.	7
Figura 7	Distribuição dos preços dos veículos.	11
Figura 8	Análise de outliers no atributo “price”.	12
Figura 9	Resultados da modelação com todos os atributos (algoritmo Gradient Boosted Trees).	15
Figura 10	Resultados da modelação com tratamento de outliers (algoritmo Gradient Boosted Trees).	16
Figura 11	Resultados da modelação com redes neuronais.	16

1 Introdução

1.1 Contextualização

1.2 Objetivos e Trabalho proposto

1.3 Resumo do trabalho a desenvolver

2 Dataset Hospitalar

Esta tarefa consistiu na análise de um dataset disponibilizado com a informação de vários utentes de diversos hospitais, como a idade, tipo sanguíneo, condição médica, dados acerca do tratamento realizado no hospital, etc. Para orientar todo o processo de resolução deste problema, adotámos a metodologia **CRISP-DM**. O CRISP-DM estabelece um guião estruturado para o desenvolvimento de projetos de análise de dados, dividido em seis etapas principais:

1. **Estudo do Negócio** (Business Understanding):
2. **Estudo dos Dados** (Data Understanding):
3. **Preparação dos Dados** (Data Preparation):
4. **Modelação** (Modeling):
5. **Avaliação** (Evaluation):
6. **Implementação** (Deployment):

2.1 Estudo do Negócio

O objetivo deste trabalho é desenvolver um modelo de previsão capaz de antecipar o resultado do teste realizado a um paciente, com base na informação disponível sobre o mesmo. Para tal, dispõe-se de dois datasets (um de treino, outro de teste) com dados de diversos indivíduos, que inclui variáveis relevantes para a análise. A ferramenta KNIME será utilizada para explorar, preparar e analisar os dados, bem como para construir e validar modelos de machine learning, permitindo assim abordar de forma estruturada e eficiente o problema em questão.

2.2 Estudo dos Dados

Ambos os datasets, ao todo, contêm 55000 entradas e 20 atributos, sendo eles:

Attribute	Descrição
Name	Nome do paciente associado ao registo clínico.
Age	Idade do paciente aquando da admissão, em anos.
Gender	Indica o género do paciente: "Masculino" ou "Feminino".
Blood Type	Grupo sanguíneo do paciente (ex: "A+", "O-", etc.).
Medical Condition	Condição médica principal ou diagnóstico (ex: "Diabetes", "Hipertensão", "Asma", etc.).
Date of Admission	Data em que o paciente foi admitido na unidade de saúde.
Doctor	Nome do médico responsável pelo acompanhamento do paciente durante a admissão.
Hospital	Identificação da unidade de saúde ou hospital onde o paciente foi admitido.
Insurance Provider	Seguradora do paciente (ex: "Aetna", "Blue Cross", "Cigna", "UnitedHealthcare", "Medicare").
Billing Amount	Valor faturado pelos serviços de saúde durante a admissão (número decimal).

Room Number	Número do quarto onde o paciente ficou alojado durante a admissão.
Admission Type	Tipo de admissão: “Urgência”, “Programada” ou “Emergência”, conforme o contexto da entrada.
Discharge Date	Data em que o paciente teve alta, calculada a partir da data de admissão e um número realista de dias.
Medication	Medicação prescrita ou administrada durante a admissão (ex: “Aspirina”, “Ibuprofeno”, “Penicilina”, “Paracetamol”, “Lipitor”).
Test Results	Resultado de exame médico realizado durante a admissão: “Normal”, “Anormal” ou “Inconclusivo”.


O atributo “Test Results” é aquele que iremos antever com o desenvolvimento de modelos de previsão através de várias técnicas de modelação

2.2.1 Test Results

No conjunto de dados, os resultados dos testes podem assumir três valores: **“Normal”**, **“Abnormal”** ou **“Inconclusive”**. Como podemos observar na imagem a seguir, a classe “Inconclusive” está sub-representada em relação às demais.

2.2.2 Age

As idades dos pacientes variam entre os 13 e os 89 anos, com maior concentração no intervalo entre os 18 e os 85 anos. A análise do gráfico revela que os resultados dos testes se mantêm relativamente consistentes ao longo das diferentes faixas etárias, com resultados de valor “Normal” predominantes em todas as idades.



2.2.3 Gender

O dataset apresenta os resultados de 25 034 pacientes do sexo masculino e 24 943 do sexo feminino, o que demonstra uma distribuição praticamente equilibrada entre gêneros. Além disso, os resultados dos testes apresentam uma distribuição equilibrada para ambos os sexos, sem desvios significativos entre homens e mulheres.




Figura 2: Distribuição dos géneros dos pacientes (após tratamento de dados).

2.2.4 Blood Type

No dataset, os tipos sanguíneos dos pacientes encontram-se distribuídos de forma equilibrada. A tabela seguinte apresenta a quantidade de pacientes por grupo sanguíneo:

Tipo sanguíneo	Quantidade
A+	6286
A-	6267
AB+	6259
AB-	6251
B+	6245
B-	6243
O+	6208
O-	6190

2.2.5 Medical Condition

Condição Médica	Quantidade
Arthritis	8388
Obesity	8344
Hypertension	8321
Diabetes	8313

Cancer	8297
Asthma	8216

2.2.6 Insurance Provider

Provedor de Seguro	Quantidade
Medicare	10066
Cigna	10021
UnitedHealthcare	9935
Blue Cross	9928
Aetna	9768

2.2.7 Medication

Medicação	Quantidade
Aspirin	9988
Lipitor	9979
Penicillin	9958
Ibuprofen	9933
Paracetamol	9920

Os dados apresentados revelam um equilíbrio entre si, refletindo também uma coerência com os diferentes tipos de resultados obtidos nos testes realizados.


2.2.8 Admission Type

Tipo de Admissão	Quantidade
Emergency	19099
Elective	16767
Urgent	13045
Immediate	968

Com base na análise, observa-se que o número de admissões do tipo “Immediate” é significativamente inferior em comparação com os restantes tipos de admissões, os quais apresentam uma distribuição relativamente equilibrada entre si.

2.2.9 Correlação entre os atributos

Como observamos na figura a seguir, existe uma correlação forte positiva entre os atributos “Date of Admission” e “Date of Discharge” e uma correlação forte negativa entre os atributos “Age” e “Year”.



2.3 Preparação dos Dados

Após a análise inicial, procedeu-se ao pré-processamento dos dados, de forma a que os valores dos vários atributos tivessem de acordo com o esperado. Assim, fizemos alterações nos seguintes atributos:

- **Billing Amount:** algumas entradas do dataset apresentavam o valor “NaN” (Not a Number), pelo que foram removidas. Em seguida, procedemos à conversão deste atributo do tipo String para Number (Double), de forma a permitir a sua análise numérica. Durante esta conversão, identificámos também valores negativos, o que consideramos que não fazia sentido num contexto hospitalar — presumivelmente, um hospital não pagaria ao paciente por um tratamento. Por isso, assumimos que se tratam de erros de escrita e removemos as respetivas entradas da tabela.
- **Date of Admission e Date of Discharge:** inicialmente, procedemos à conversão do atributo “Date of Discharge” de String para o tipo Date. Como estes dois atributos apresentavam uma correlação bastante elevada entre si, optámos por tirar melhor partido destes atributos ao criar um novo atributo — “**Duration of Stay**” — utilizando o nó “Date&Time Difference”, que calcula o número de dias entre a data de admissão e a alta hospitalar. Após essa transformação, removemos os atributos originais.
- **Name, Doctor e Hospital:** optámos por remover estas colunas, uma vez que apresentam um número excessivo de valores distintos. Considerámos que esta elevada cardinalidade não contribuiria de forma relevante para a construção dos modelos de previsão, podendo até introduzir ruído desnecessário.
- **Floor:** excluimos este atributo devido à sua forte correlação com o atributo “Room Number”, o que poderia resultar em redundância de informação nos modelos. Adicionalmente, a presença

de missing values reforçou a decisão de remoção, evitando assim a necessidade de tratamentos adicionais.

2.3.1 Normalização de valores categóricos

Vários atributos apresentavam nomenclaturas distintas para representar o mesmo valor, ou continham erros ortográficos. Para corrigir estas inconsistências, recorremos ao nó “String Replacer (Dictionary)”, que, com base no dicionário apresentado abaixo, substituiu automaticamente as palavras pelos valores corretos.

2.3.2 Tratamento de valores em falta (missing values)

Alguns atributos apresentavam entradas com valores em falta. A tabela a seguir mostra os atributos com a respetiva quantidade de missing values.

Os missing values de cada atributo foram tratados da seguinte forma:

- **Medication e Insurance Provider:** substituímos pelo valor mais frequente do dataset
- **Age:** substituímos pela mediana dos valores.
- **Blood Type:** removemos as entradas com valores em falta, por considerarmos ser um atributo essencial para a construção dos modelos de previsão e, obviamente, não faz sentido existirem pacientes sem qualquer sangue a circular no respetivo organismo.

2.3.3 Oversampling dos dados

Para corrigir o desequilíbrio entre as diferentes classes dos resultados de teste, recorremos a técnicas de oversampling, nomeadamente através da aplicação do nó “SMOTE”. Este nó permite aumentar artificialmente o número de exemplos nas classes menos representadas, gerando novas entradas sintéticas com base nos dados existentes. Após a aplicação deste nó, a distribuição dos resultados de teste tornou-se mais equilibrada entre as diferentes classes, como se pode observar no gráfico abaixo:

2.3.4 Normalização dos valores numéricos

De forma a evitar a elevada dispersão de valores, procedemos à normalização do atributo “Billing Amount”. Para tal, utilizámos o método de min-max scaling, que transforma os valores para o intervalo definido (neste caso, o intervalo [0,1]). Embora outros métodos de normalização pudessem ser aplicados, esta abordagem revelou-se adequada e não se esperariam diferenças significativas nos resultados finais com a utilização de métodos alternativos.

2.4 Modelação

2.4.1 Modelação com todos os atributos.

Dado que o dataset apresentava um problema de classificação, utilizamos nós de árvores de decisão, nomeadamente **Decision Tree**, **Random Forest** e **Gradient Boosting**. Para aumentar a fiabilidade dos resultados, utilizámos também nós de cross validation, permitindo executar os algoritmos múltiplas vezes e assim obter avaliações mais robustas do desempenho dos modelos, em comparação com uma simples divisão dos dados (partitioning).

No nó X-Partitioner, seleccionámos a opção de Stratified sampling na coluna objetivo (Test Results), de forma a garantir que as proporções de cada classe de resultado de teste se mantinham consistentes em todas as partições dos dados.“

Obtivemos o melhor resultado através do algoritmo **Random Forest**. Entre os algoritmos utilizados, obtivemos uma melhor “accuracy” igual a 57,03%, com o valor de Cohen’s kappa obtido igual a 0,356.

	Abnormal (Predicted)	Inconclusive (Predicted)	Normal (Predicted)	
Abnormal (Actual)	9909	3444	9322	43.70%
Inconclusive (Actual)	3298	14200	5177	62.62%
Normal (Actual)	5392	2595	14688	64.78%
	53.28%	70.16%	50.32%	

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
57.03%	42.97%	0.356	38797	29228

Figura 4: Resultados da modelação com todos os atributos.

2.4.2 Modelação com feature selection.

Para identificar os atributos mais relevantes para o modelo de previsão, utilizámos a estratégia de feature selection. Esta abordagem permite, através de testes sistemáticos, determinar quais os atributos que contribuem para uma maior precisão (accuracy) do modelo.

Os atributos que foram seleccionados pelo processo de feature selection foram “Age”, “Year”, “Gender”, “Blood Type”, “Medical Condition”, “Insurance Provider”, “Room Number”, “Admission Type”, “Medication”, “Duration of Stay” e “Test Results”. Após treinar os modelos utilizando apenas os atributos seleccionados no processo anterior, o algoritmo **Random Forest** apresentou os seguintes resultados:

	Abnormal (Predicted)	Inconclusive (Predicted)	Normal (Predicted)	
Abnormal (Actual)	10898	3007	8770	48.06%
Inconclusive (Actual)	2626	16653	3396	73.44%
Normal (Actual)	5910	2527	14238	62.79%
	56.08%	75.06%	53.92%	

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
61.43%	38.57%	0.421	41789	26236

Figura 5: Resultados da modelação com feature selection.

2.4.3 Modelação com os dados em bins.

Com base nos atributos seleccionados durante o processo de feature selection, procedemos à discretização dos valores numéricos em intervalos (bins). Esta abordagem permitiu agrupar os dados em categorias distintas, resultando nos seguintes resultados:

	Abnormal (Predicted)	Inconclusive (Predicted)	Normal (Predicted)	
Abnormal (Actual)	9074	4854	8747	40.02%
Inconclusive (Actual)	3902	12992	5781	57.30%
Normal (Actual)	5195	4868	12612	55.62%
	49.94%	57.20%	46.47%	

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
50.98%	49.02%	0.265	34678	33347

Figura 6: Resultados da modelação com dados em bins.

2.5 Avaliação

O algoritmo Random Forest destacou-se de forma consistente como a melhor opção entre os modelos de previsão desenvolvidos.

Na modelação utilizando todos os atributos disponíveis, o Random Forest atingiu uma precisão (accuracy) de 57,03% e um valor de Cohen's kappa de 0,356. Embora estes resultados revelem uma capacidade de previsão superior ao acaso, continuam a refletir um desempenho moderado, evidenciando a complexidade inerente ao problema de classificação em análise.

A aplicação da técnica de feature selection permitiu identificar os atributos mais relevantes para o modelo: "Age", "Year", "Gender", "Blood Type", "Medical Condition", "Insurance Provider", "Room Number", "Admission Type", "Medication", "Duration of Stay" e "Test Results". Com esta seleção, o desempenho do Random Forest registou uma ligeira melhoria, confirmando a importância de uma escolha criteriosa das variáveis de previsão.

Por outro lado, a discretização dos valores numéricos em intervalos (bins) resultou em desempenhos ligeiramente inferiores aos obtidos com as abordagens anteriores. Embora esta técnica possa facilitar a interpretação dos dados pelo modelo, não se verificaram ganhos significativos em termos de performance.

Em suma, a complexidade do problema é evidente nos resultados alcançados, mesmo com os melhores modelos. A tarefa de classificar os resultados dos testes com base nas variáveis disponíveis no dataset revelou-se particularmente desafiante, sobretudo devido à fraca correlação entre os diferentes atributos.

Ainda assim, o Random Forest demonstrou ser a abordagem mais robusta, graças à sua capacidade de lidar com diferentes tipos de dados e de mitigar o risco de overfitting, destacando-se como a solução mais adequada para o contexto em estudo.

Numa última nota, para este problema ainda tentamos converter o atributo objetivo para valores contínuos, de forma a tratar o problema como um problema de regressão. No entanto, os resultados foram extremamente baixos (R^2 aproximadamente igual a 0), pelo que optámos por não os incluir.

3 Dataset de grupo - car prices

Esta tarefa consiste na análise de um dataset escolhido pelo grupo.

Após explorarmos vários datasets disponíveis na plataforma Kaggle, optámos por escolher com o dataset “Car Prices”. A nossa escolha recaiu sobre este dataset devido à sua quantidade considerável de atributos e ao bom equilíbrio entre dados nominais e numéricos. Adicionalmente, embora este dataset não exija um tratamento de dados tão extenso como o dataset atribuído na tarefa anterior, permite-nos complementar o trabalho já realizado e demonstrar competências que ainda não tivemos oportunidade de evidenciar, nomeadamente a resolução de problemas de regressão linear e a identificação e tratamento de outliers.

Para abordar este problema, seguimos novamente a metodologia CRISP-DM, tal como apresentamos na tarefa anterior

3.1 Estudo do Negócio

O objetivo deste problema é identificar, com o apoio de modelos de aprendizagem automática, quais os atributos que mais influenciam o preço dos veículos no setor automóvel. Para tal, dispõe-se de um dataset com informação detalhada sobre diversos tipos de carros e recorre-se à plataforma KNIME, que permite tanto a análise de dados como a construção de modelos de machine learning, facilitando assim a resolução estruturada deste problema.

3.2 Estudo dos Dados

O dataset do problema contém 205 entradas e 26 atributos, descritos na seguinte tabela:

Atributo	Descrição
Car_ID	Identificador único do veículo no conjunto de dados.
symboling	O nível de risco, para efeitos do seguro automóvel. Um valor de +3 indica que o carro é apresenta um risco elevado, -3 que é provavelmente bastante seguro.
CarName	Nome do carro (marca e modelo).
fueltype	Tipo de combustível (gasolina ou diesel).
aspiration	Tipo de entrada de ar no motor (standard/turbo).
doornumber	Número de portas do carro (two/four).
carbody	Tipo de carroçaria.
drivewheel	Tipo de tração do veículo (FWD/RWD/4WD).
enginelocation	Localização do motor no veículo (front/rear).
wheelbase	Distância entre os eixos dianteiro e traseiro.
carlength	Comprimento do carro.
carwidth	Largura do carro.
carheight	Altura do carro.
curbweight	Peso do veículo sem ocupantes ou bagagem.
enginetype	Tipo de motor.
cylindernumber	Número de cilindros do motor.
enginesize	Tamanho do motor (em polegadas cúbicas).

fuelsystem	Tipo de sistema de injeção de combustível.
bore ratio	Rácio entre o diâmetro do cilindro e a distância que o pistão percorre.
stroke	Distância que o pistão percorre.
Compressionratio	Rácio entre o volume do cilindro e a câmara de combustão.
horsepower	Número de cavalos de potência.
peakrpm	Número máximo de rotações/minuto que o motor atinge.
citympg	Média de consumo de combustível (em milhas por galão) em condições citadinas.
highwaympg	Média de consumo de combustível (em milhas por galão) em condições de autoestrada.
price	Preço do carro.

O dataset encontra-se disponível **aqui**.

3.2.1 Análise individual de cada atributo.

Os preços dos carros variam entre 5.118 e 45.400, sendo a média igual a 13276. Através da análise do seguinte gráfico, verificamos que a maioria dos preços dos veículos situa-se abaixo dos 20.000.




Figura 7: Distribuição dos preços dos veículos.

Também identificamos a presença de outliers neste atributo, conforme se verifica no box plot abaixo apresentado.




Figura 8: Análise de outliers no atributo “price”.

aspiration – Os veículos com uma entrada de ar **standard** têm em média um preço de 12.611 enquanto que os que têm **turbo** têm em média um preço de 16.298. A correlação entre este atributo e price é igual a 0,309, o que indica que o tipo de entrada de ar no motor afeta o preço do carro.

cylindernumber – O número de cilindros no motor de um carro afetam o preço total do veículo. Apesar de cerca de 75% dos veículos presentes no dataset terem 4 cilindros, conseguimos agrupar este atributo em 3 grupos em relação ao preço médio do carro. Um carro com 2, 3 ou 4 cilindros no motor tem um valor em média de 10000, um carro com 5 ou 6 cilindros tem um valor em média de 22000, e um carro com 8 ou 12 cilindros tem um valor em média de 36000. Podemos então concluir que em geral quantos mais cilindros o motor possui maior será o preço do carro.

enginesize – O tamanho do motor de um veículo também afeta o respetivo preço final, sendo que quanto maior o tamanho do motor, maior é o valor do veículo. A correlação entre este atributo e o atributo “price” é igual a 0,874, sendo considerada bastante forte.

boreratio – Este atributo não parece exercer um efeito significativo sobre o preço final do carro quando analisamos o atributo através de um nodo scatter plot. No entanto, esse atributo possui uma correlação de 0,6438 com o preço do veículo, o que indica que existe uma relação entre os 2 atributos.

stroke – Este atributo parece não influenciar o preço dos carros pois apresenta uma correlação de apenas 0,1113.

compressionratio – De forma semelhante ao atributo stroke, este atributo do carro não influencia de forma significativa o preço do veículo.

horsepower – A potência produzida pelo motor influencia diretamente o valor do carro, já que veículos com um motor com maior potência tendem a valer mais. Este atributo apresenta uma correlação com o preço do veículo igual a 0,8546.

peakrpm – Não parece existir qualquer correlação significativa entre o número máximo de rotações por minuto e o preço do veículo.

fueltypes: Os veículos que utilizam o tipo de combustível **gas** (gasolina) têm em média um preço aproximadamente igual a 13.000 enquanto que os carros a **diesel** (gasóleo) têm em média um preço de 15.838. No entanto, neste dataset, cerca de 90% dos carros utilizam gasolina. Logo, não é possível tirar uma conclusão sobre o efeito real do tipo do combustível no preço.

fuelsystem – Existem 8 tipos de sistemas de combustíveis no dataset analisado. Na tabela abaixo fizemos a análise deste atributo.

Tipo de sistema de combustível	Média do preço dos veículos	% veículos
mpfi	17.754	45,85%
2bbl	74.78	32,2%
mfi	12.964	0,49%
1bbl	7.555	5,37%
spfi	11.048	0,49%
4bbl	12.145	1,46%
idi	15.838	9,76%
spdi	10.990	4,39%

A tabela revela que o sistema de combustível **mpfi** é o mais frequente e apresenta a maior média de preços, sugerindo que é o mais utilizado em veículos com preços acima da média do dataset (a média de preços é igual a 13.276). Em contraste, o tipo **2bbl**, o segundo mais comum, possui a menor média de preços, indicando que este tipo é mais predominante em veículos mais acessíveis. Para os demais tipos de sistema de combustível, a falta de dados exemplificativos não nos permite tirar uma conclusão.

citympg – Este atributo apresenta a média de consumo de combustível (em milhas por galão) em condições urbanas. É possível verificar que quanto menor for esse valor, maior tende a ser o preço do veículo. O valor da correlação deste atributo com o preço é igual a $-0,6858$.

highwaympg – Este atributo apresenta a média de consumo de combustível (em milhas por galão) em condições de autoestrada. À semelhança do atributo **citympg**, é possível verificar que quanto menor for esse valor, maior tende a ser o preço do veículo. O valor da correlação deste atributo com o preço é igual a $-0,6976$.

enginelocation – Existem veículos com o motor localizado na parte da frente, que têm um preço médio igual a 12.961 e um nível de ocorrências de 98.54% e os que têm o motor localizado na traseira e que têm um preço médio de 34.528 e um nível de ocorrências igual a 1.46%.

wheelbase – Este atributo representa a distância entre os eixos no veículo, sendo possível verificar que quanto maior for a distância, maior tende a ser o preço do veículo.

carlength – Este atributo representa o comprimento do veículo, e é possível verificar que quanto maior for o comprimento, maior tende a ser o preço do veículo.

carwidth – Este atributo representa a largura do veículo, e é possível verificar que quanto maior for a largura, maior tende a ser o preço do veículo.

carheight – Este atributo representa a altura do veículo, e não é possível verificar qualquer relação entre esta característica e o preço do veículo.

curbweight – Este atributo representa a tara do veículo, ou seja, o peso do veículo sem quaisquer ocupantes ou carga, e com o tanque de combustível cheio, e é possível verificar que quanto maior for este valor, maior tende a ser o preço do veículo.

symboling – Este atributo indica o fator de risco associado ao preço do veículo. Pela análise realizada ao atributo não foi possível chegar a uma conclusão concreta sobre como afeta o preço dos veículos devido à falta de exemplos de carros com preços elevados.

name – Este atributo indica o nome do carro, ou seja, a marca e o modelo. Analisando este atributo não conseguimos tirar uma conclusão sobre o seu efeito no preço do veículo devido à quantidade de diferentes tipos de nomes que existem no dataset. No entanto, podemos realizar uma análise apenas ao fabricante do veículo, extraíndo-o de cada nome. Podemos notar que o preço de cada marca não varia muito de carro para carro. As marcas com os veículos com o valor mais alto neste dataset são Jaguar, Buick, Porsche e BMW com um valor médio acima dos 25.000. As outras marcas possuem um valor médio entre os 6.000 e 18.000.

drivewheels – Este atributo representa o tipo de tração do veículo. A tabela seguinte apresenta as estatísticas deste atributo.

Tipos de rodas motrizes	Média do preço dos veículos	% veículos
fwd	9.239	58,54%
4wd	19.919,8	4,39%
rwd	11.087	37,07%

Como é possível observar, o tipo **fwd** é o que apresenta uma maior percentagem de ocorrências e um menor preço médio do veículo.

enginetype – Este atributo representa o tipo de motor. A tabela seguinte apresenta as estatísticas deste atributo.

Tipos de motor	Média do preço dos veículos	% veículos
ohc	11.574	72,2%
l	14.627	5,85%
dohcv	31.400	0,49%
dohc	18.116	5,85%
rotor	13.020	1,95%
ohcv	25.098	6,34%
ohcf	13.738	7,32%

Como é possível observar, o tipo **ohc** é o que apresenta uma maior percentagem de ocorrências e um menor preço médio do veículo.

3.3 Preparação dos Dados

Após a análise inicial, procedeu-se ao pré-processamento dos dados. A coluna “Car_ID” foi removida por conter valores únicos para cada entrada, tornando-a irrelevante para a modelagem. Adicionalmente, o software KNIME atribui automaticamente um identificador único a cada linha, redundando a necessidade desta coluna.

Conforme mencionado anteriormente, a designação do fabricante foi extraída do nome de cada veículo. Este processo envolveu, primeiramente, a divisão do nome em marca e modelo através do nó “string splitter (regex)”. Posteriormente, identificados erros de escrita em algumas marcas, aplicou-se o nó “string replacer (dictionary)” para realizar as devidas correções.

Para proceder à modelação através de redes neuronais, foi necessário converter os dados do dataset para o tipo **double**, pois o nó de aprendizagem apenas aceita valores deste tipo. Para tal, recorremos ao nó “category to number” que transforma os valores categóricos em números inteiros e, posteriormente, utilizamos o nó “math formula”, para converter os valores inteiros em double.

Adicionalmente, os dados foram normalizados para o intervalo de 0 a 1 utilizando o nó “normalizer”. Para permitir a comparação dos valores previstos na escala original do problema no momento da avaliação (pelo scorer), foi necessário duplicar a coluna “price” e renomeá-la para “Prediction(price)”. Esta etapa assegura que a função de normalização possa normalizar e, posteriormente, desnormalizar o atributo gerado pelo Predictor.

3.4 Modelação

3.4.1 Modelação com todos os atributos.

Para a modelação do problema, começamos por utilizar os nodos de aprendizagem de regressão linear sobre todos os atributos do dataset. Para este modelo e para todos os restantes, utilizamos **cross validation**, de forma a avaliarmos o modelo para diferentes grupos de treino e teste. Os algoritmos utilizados foram **Simple Regression Tree** e **Gradient Boosted Trees (Regression)**, dos quais obtivemos os seguintes resultados.

A análise comparativa destes algoritmos revelou que o algoritmo **Gradient Boosted Trees** oferece melhores resultados, razão pelo qual o escolhemos para testar os restantes modelos.

R ² :	0,929
Mean absolute error:	1 405,021
Mean squared error:	4 505 252,81
Root mean squared error:	2 122,558
Mean signed difference:	28,058
Mean absolute percentage error:	0,106
Adjusted R ² :	0,929

Figura 9: Resultados da modelação com todos os atributos (algoritmo Gradient Boosted Trees).

Para além disso, testamos novamente estes algoritmos, mas aplicando o pré-tratamento aos valores atípicos (outliers), onde estes foram substituídos pelo valor permitido mais próximo. Observou-se uma ligeira melhoria nas métricas de desempenho:

R ² :	0,937
Mean absolute error:	1 122,918
Mean squared error:	2 843 747,14
Root mean squared error:	1 686,341
Mean signed difference:	18,547
Mean absolute percentage error:	0,094
Adjusted R ² :	0,937

Figura 10: Resultados da modelação com tratamento de outliers (algoritmo Gradient Boosted Trees).

3.4.2 Modelação com feature selection.

O processo de feature selection permite-nos seleccionar quais os atributos mais relevantes para a construção dos modelos de previsão. Para tal, recorremos aos nós “feature selection loop start”, “feature selection loop end” e “feature selection filter”.

Este processo de selecção de atributos foi conduzido de acordo com a avaliação do impacto de cada atributo no desempenho do modelo. Para esta avaliação, foram consideradas 3 métricas distintas – **R²**, **Mean Absolute Error** (MAE) e **Root Mean Squared Error** (RMSE).

Nos processos em que a métrica de avaliação foi o **R²** e o RMSE, os atributos que obtiveram o melhor resultado foram o carbody, wheelbase, carlength, carwidth, carheight, curbweight, fuelsystem, boreratio, peakrpm e citympg, com valores iguais a 0,969 para a métrica **R²** e a 1.388,07 para a métrica RMSE. O resultado obtido para a métrica MAE foi igual a 1.065,67, para os atributos symboling, carbody, wheelbase, carlength, carwidth, carheight, curbweight, cylindernumber, fuelsystem, boreratio, peakrpm, citympg, highwaympg. Estes resultados mostram melhorias significativas em relação àquilo que obtivemos quando testamos com todos os atributos.

3.4.3 Modelação com redes neuronais.

À semelhança do que acontece no cérebro humano, as redes neuronais processam informação através de camadas de neurónios interligados por sinapses, onde o valor dessas ligações é ajustado durante a aprendizagem. Esta estrutura permite que a rede identifique padrões complexos e relações significativas nos dados de entrada, aprendendo a realizar tarefas específicas a partir de exemplos.

Para tal, recorremos aos nós **RProp MLP Learner** e **MultiLayerPerceptron Predictor**.

No nodo de aprendizagem, definimos o número máximo de iterações igual a 600, 5 camadas escondidas e 10 neurónios contidos em cada camada.

A imagem a seguir apresentada mostra os resultados obtidos.

R ² :	0,893
Mean absolute error:	1 928,789
Mean squared error:	8 560 791,999
Root mean squared error:	2 925,883
Mean signed difference:	463,41
Mean absolute percentage error:	0,147
Adjusted R ² :	0,893

Figura 11: Resultados da modelação com redes neuronais.

3.5 Avaliação

A avaliação dos modelos de regressão para prever os preços dos carros revelou que o algoritmo Gradient Boosted Trees se destacou, apresentando um R^2 de 0,929, um erro absoluto médio de 1.405,021, um erro quadrático médio de 4.505.252,81 e uma raiz do erro quadrático médio de 2.122,558. Após o tratamento de outliers, houve uma melhoria, com o R^2 aumentando para 0,937, o erro absoluto médio diminuindo para 1.122,918 e a raiz do erro quadrático médio para 1.686,341.

A seleção de atributos mostrou-se eficaz para melhorar os modelos. Utilizando R^2 e RMSE como métricas, os atributos mais relevantes foram identificados como carbody, wheelbase, carlength, carwidth, carheight, curbweight, fuelsystem, boreratio, peakrpm e citympg, alcançando um R^2 de 0,969 e um RMSE de 1.388,07. Ao utilizar o erro absoluto médio como métrica, os atributos selecionados foram symboling, carbody, wheelbase, carlength, carwidth, carheight, curbweight, cylindernumber, fuelsystem, boreratio, peakrpm, citympg e highwaympg, resultando em um erro absoluto médio de 1.065,67.

Em contraste, a modelagem com redes neurais apresentou um desempenho inferior, com um R^2 de 0,893, um erro absoluto médio de 1.928,789 e uma raiz do erro quadrático médio de 2.925,883.

É importante destacar que nem todos os atributos do dataset contribuíram significativamente para a precisão dos modelos. Atributos como stroke, compressionratio e name mostraram correlação reduzida com o preço dos veículos, o que se confirmou durante o processo de feature selection. Por outro lado, atributos como fuelsystem, wheelbase, curbweight e carwidth demonstraram uma forte correlação com o preço final.

Em conclusão, para este problema específico de previsão de preços de carros, o algoritmo Gradient Boosted Trees, especialmente com a seleção de atributos, apresentou claramente o melhor desempenho em todas as métricas avaliadas. As redes neurais, apesar da sua reconhecida capacidade de modelar relações complexas, não se mostraram adequadas para este conjunto de dados específico com a configuração utilizada, obtendo resultados consideravelmente inferiores (R^2 de “apenas” 0,893) em comparação com os outros modelos.

4 Conclusão

Ao longo deste projeto abordámos dois problemas bem distintos, um de classificação hospitalar (dataset atribuído pela equipa docente) e outro de regressão de preços de automóveis (dataset escolhido pelo grupo). Aplicando a metodologia CRISP-DM de ponta a ponta e explorando várias estratégias de preparação e modelação de dados:

Dataset hospitalar (problema de classificação): Exigiu um maior foco no tratamento de dados: correção de valores em falta, uniformização de categorias e criação de novas variáveis e atenuação de desequilíbrios através de técnicas de oversampling. Ainda assim, o melhor modelo (Random Forest) estabilizou-se numa accuracy de cerca de 61 %, revelando tanto o valor informativo das variáveis como a dificuldade inerente ao domínio.

Dataset de preços de automóveis (problema de regressão): Após remover alguns outliers e transformar as variáveis categóricas, a seleção dos atributos mais preditivos (peso, cilindrada, dimensão, tipo de combustível) permitiu ao Gradient Boosted Trees atingir $R^2 \approx 0,97$ e RMSE cerca de 1 400, superando a regressão linear, árvores simples e redes neuronais.

Ao longo da elaboração do trabalho, constatámos que a preparação de dados foi crucial e proporcionou melhores resultados do que simplesmente trocar de algoritmo, os modelos em árvore foram os mais consistentes: Random Forest lida bem com classes mistas e Gradient Boosted Trees captou relações não-lineares com alto poder explicativo, a seleção de atributos reduziu o ruído e o custo computacional sem comprometer a performance e ainda que a validação rigorosa com stratified k-fold foi também fulcral para obter resultados positivos.

Em suma, conseguimos construir processos completos que, embora sujeitos a limitações impostas pela qualidade intrínseca dos dados clínicos, provaram ser eficazes para explorar cenários reais de machine learning. No dataset hospitalar atingimos um compromisso aceitável entre precisão e interpretabilidade, identificando variáveis-chave (Age, Gender, Medication, Duration of Stay, etc.) que podem apoiar decisões clínicas futuras. Já no dataset de preços de automóveis demonstrámos que, com tratamento de outliers e seleção de atributos técnicos (wheelbase, curbweight, carwidth, fuelsystem, citympg...), é possível prever preços com erro inferior a 1 400 em média, evidenciando valor prático para concessionários ou plataformas de venda online. Estes resultados validam os objetivos propostos e confirmam a importância de combinar rigor no tratamento de dados, escolha criteriosa de atributos e modelos adaptados à natureza do problema para alcançar soluções fiáveis de Aprendizagem e Decisão Inteligentes.